

Devoir3

EL_Hadrami

23/12/2020

```
library("FactoMineR")
library("factoextra")
```

```
## Loading required package: ggplot2
```

```
## Welcome! Want to learn more? See two factoextra-related books at https://goo.gl/ve3WBa
```

```
library("corrplot")
```

```
## corrplot 0.84 loaded
```

Exercice 1

```
Z1 <- c(1:3,4,9)
Z2 <- c(5,10,rep(8,2),12)
n <- length(Z2)
mat <- matrix(c(Z1,Z2),nrow=2,ncol=5,byrow = TRUE,dimnames = list(c("Z1","Z2")))
meanZ1 <- mean(mat[1,])
meanZ2 <- mean(mat[2,])
miZ1 <- sd(mat[1,])
miZ2 <- sd(mat[2,])
Z1norm <- (Z1 - mean(Z1)) / sd(Z1)
Z2norm <- (Z2 - mean(Z2)) / sd(Z2)
matnorm <- matrix(c(Z1norm,Z2norm),nrow=2,ncol=5,byrow = TRUE,dimnames = list(c("Z1","Z2")))
# Matrice de correlation
matcorr <- (1/4) * (matnorm %*% t(matnorm))
# valeurs propres et vecteurs propres
eig <- eigen(matcorr)
valp1 <- eig$values[1]
vp1 <- eig$vectors[,1]
valp2 <- eig$values[2]
vp2 <- eig$vectors[,2]
# Cercle de correlation contenant les vecteurs X1 et X2
X1 <- sqrt(valp1) * vp1
X2 <- sqrt(valp2) * vp2
```

1.ACP sur la main

```
df <- as.data.frame(mat)
res.pca <- PCA(df,scale.unit = TRUE ,graph = FALSE)
```

2. Interpretation

3.Utilisation des commandes

```
# Standardisation des données
s1 <- scale(x = Z1,center=TRUE,scale=TRUE)
```

```
s2 <- scale(x = Z2,center=TRUE,scale=TRUE)
mats <- matrix(c(s1,s2),nrow = 2,ncol=5,byrow = TRUE)
```

fonction gsvd

```
gsvd <- function(Z,r,c){
  #Z matrice numerique de dimension (n,p) et de rang k
  #r poids de la metrique des lignes N=diag(r)
  #c poids de la metrique des colonnes M=diag(c)
  #-----sortie-----
  # d vecteur de taille k contenant les valeurs singulieres (racines carrees des valeurs propres)
  # U matrice de dimension (n,k) des vecteurs propres de de ZMZ'N
  # V matrice de dimension (p,k) des vecteurs propres de de Z'NZM
  k <-qr(Z)$rank
  colnames<-colnames(Z)
  rownames<-rownames(Z)
  Z <-as.matrix(Z)
  Ztilde <-diag(sqrt(r)) %*% Z %*%diag(sqrt(c))
  e <-svd(Ztilde)
  U <-diag(1/sqrt(r))%*%e$u[,1:k] # Attention : ne s'ecrit comme cela que parceque N et M sont diagonale
  V <-diag(1/sqrt(c))%*%e$v[,1:k]
  d <- e$d[1:k]
  rownames(U) <- rownames
  rownames(V) <- colnames
  if(length(d)>1)
    colnames(U) <-colnames(V) <-paste("dim", 1:k, sep = "")
  return(list(U=U,V=V,d=d))
}
r <-rep(1/nrow(mats),nrow(mats)) #lignes ponderees par 1/n
c <-rep(1/ncol(mats)) #colonnes ponderees par 1
U <-gsvd(mats,r,c)$U
d <-gsvd(mats,r,c)$d
Psi <- U %*%diag(d)
#princomp(mat,cor=TRUE)
```

Exercice 2

```
# load data
data_ski <- read.table("data/stations.txt",header = TRUE)
# extraction des variables quantitatives
data_ski_active <- as.matrix(data_ski[1:32,2:7])
rownames(data_ski_active) <- data_ski$Nom
summary(data_ski_active)
```

```
##      prixforf      altmin      altmax      pistes      kmfond
## Min.       : 42.00   Min.       : 500   Min.       :1600   Min.       : 0.00   Min.       : 0.0
## 1st Qu.: 81.75   1st Qu.:1138   1st Qu.:2275   1st Qu.: 26.00   1st Qu.: 9.5
## Median : 95.50   Median :1400   Median :2600   Median : 34.00   Median :22.0
## Mean   :104.69   Mean   :1323   Mean   :2567   Mean   : 49.44   Mean   :27.5
## 3rd Qu.:140.00   3rd Qu.:1550   3rd Qu.:2838   3rd Qu.: 71.00   3rd Qu.:36.5
## Max.    :160.00   Max.    :1850   Max.    :3450   Max.    :129.00   Max.    :80.0
##      remontee
## Min.       : 4.00
## 1st Qu.: 17.00
## Median : 23.00
```


```
## Mean : 33.81
## 3rd Qu.: 45.75
## Max. :110.00
```

PCA

```
pcaski <- PCA(data_ski_active, scale.unit = T, graph = FALSE)
# Visualisation des valeurs propres
valp <- pcaski$eig
```

Graphe des valeurs propres

```
fviz_eig(pcaski, addlabels = TRUE, ylim = c(0, 50))
```



Les deux premières composantes principales expliquent 74% de la variation, donc les deux premiers axes peuvent être acceptés.

Graphique des variables


```
var <- get_pca_var(pcaski)
```

Coordonnées des variables

```
var$coord
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## prixforf  0.93031706  0.09513297 -0.08572117  0.1251448 -0.31055554
## altmin   -0.07336694  0.82270492  0.48871130  0.2792394  0.02904032
## altmax    0.65006226  0.53099234 -0.03832048 -0.5398817  0.04967488
## pistes    0.95404437 -0.06226765 -0.11082956  0.1446174  0.05250905
## kmfond    0.36193326 -0.50154750  0.76829658 -0.1613207 -0.03250806
## remontee  0.92973674 -0.14239486 -0.03422684  0.1886935  0.23708189
```

```
fviz_pca_var(pcaski, axes = c(1,2))
```

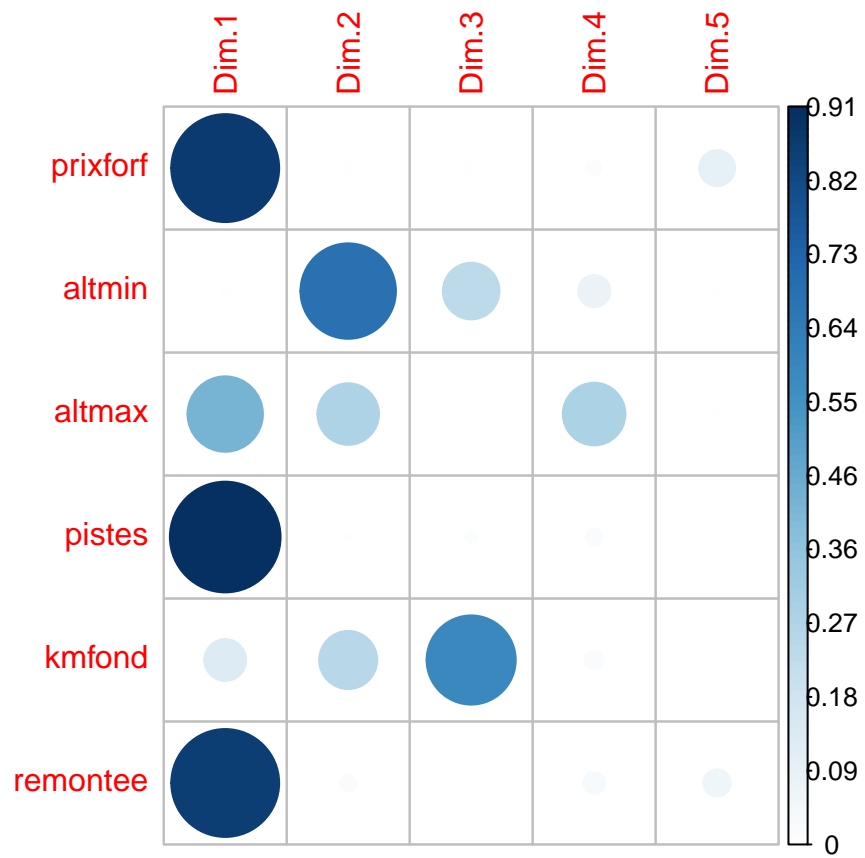


Interpretation


- Les variables positivement corrélées sont regroupées
- Les variables négativement corrélées sont positionnées sur les côtés opposés de l'origine du graphique (quadrants opposés).
- La distance entre les variables et l'origine mesure la qualité de représentation des variables, les variables qui sont loin de l'origine sont bien représentées par l'ACP.

Qualité de représentation des variables

```
corrplot(var$cos2, is.corr = FALSE)
```




```
fviz_cos2(pcaski, choice = "var", axes = 1 :2)
```



Interpretations

Un cos2 élevé indique une bonne représentation de la variable sur les axes principaux en considération (comme on peut le voir)

```
fviz_pca_var(pcaski, col.var = "cos2", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE)
```



Contributions des variables


```
var$contrib
```

```
##          Dim.1      Dim.2      Dim.3      Dim.4      Dim.5
## prixforf 27.0545026  0.7277779  0.8630735  3.348903 60.3619164
## altmin   0.1682591 54.4283218 28.0528130 16.673650  0.5278217
## altmax   13.2095337 22.6732235  0.1724779 62.326754  1.5443938
## pistes   28.4521266  0.3117897  1.4427227  4.472173  1.7256503
## kmfond    4.0948176 20.2283699 69.3313170  5.564903  0.6614036
## remontee 27.0207604  1.6305172  0.1375958  7.613617 35.1788143
```

```
corrplot(var$contrib,is.corr = FALSE)
```



```
fviz_contrib(pcaski, choice = "var", axes = 1 :2, top = 6)
```





Interpretation

La ligne en pointillé rouge, sur le graphique ci-dessus, indique la contribution moyenne attendue.
Donc les variables les plus contributives sont **piste**, **remontee** et **prixfort**


Diagramme circulaire des variables contributives

```
fviz_pca_var(pcaski, col.var = "contrib", gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), alha.var="c
```




Graphiques des individus

```
ind <- get_pca_ind(pcaski)
fviz_pca_ind (pcaski, col.ind = "cos2",gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),repel = TRUE)
```



```
fviz_contrib(pcaski, choice = "ind", axes = 1 :2)
```

Contribution of individuals to Dim-1-2



Biplot

```
fviz_pca_biplot(pcaski,
  repel = TRUE,
  col.var = "#2E9FDF", # Couleur des variables
  col.ind = "#696969") # Couleur des individus )
```

